

Distances

Dans tout projet d'analyse de données, il est nécessaire de pouvoir quantifier la ressemblance (ou la dissemblance) entre deux observations. Pour cela, on utilise la notion de **distance** (ou **similarité**) entre les observations. Le choix de cette distance influence directement les résultats des algorithmes d'apprentissage, de regroupement et de visualisations.

1 Notion de distance

Une **distance** est une fonction mathématique mesurant à quel point deux objets sont éloigné l'un de l'autre dans un espace donnée. Plus la distance est grande, plus les observations sont éloigné.

Définition de mesure de distance

Une fonction $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est une distance sur un ensemble $\mathcal{X}$ si, pour tout $x, y, z \in \mathcal{X}$, les conditions suivantes sont vérifiées :

1. non-négativité : $d(x, y) \geq 0$;
2. séparation : $d(x, y) = 0 \Leftrightarrow x = y$;
3. symétrie : $d(x, y) = d(y, x)$;
4. inégalité triangulaire : $d(x, y) \leq d(x, z) + d(y, z)$.

La distance euclidienne

Lorsque les observations sont représentées par des vecteurs numériques dans $\mathbb{R}^p$ de même ordre de grandeur, la **distance euclidienne** est souvent un bon choix.

Soit $x, y \in \mathbb{R}^p$, la distance euclidienne est donnée par :

$$d(x, y) = \|x - y\|_2 = \left(\sum_{i=1}^p (x_i - y_i)^2 \right)^{1/2}.$$

La distance L_q (ou de Minkowski)

Soit $x, y \in \mathbb{R}^p$, la distance L_q est donnée, pour $q > 0$, par :

$$d(x, y) = \|x - y\|_q = \left(\sum_{i=1}^p |x_i - y_i|^q \right)^{1/q}.$$

Cas particuliers :

— Pour $q = 1$, on obtient la distance de Manhattan :

$$d(x, y) = \|x - y\|_1 = \sum_{i=1}^p |x_i - y_i|.$$

— Pour $q = 2$, on obtient la distance euclidienne.

Exemple

Considérons le jeu de données suivant :

TABLE 1 : Taille et poids moyens au Canada (Source : Statistique Canada, Enquête sur la santé dans les collectivités canadiennes (2008)).

Nom	Taille	Poids
Alice	162.1	66.8
Bob	175.8	81.6

La distance euclidienne entre Alice et Bob est

$$d(\text{Alice}, \text{Bob}) = \sqrt{(162.1 - 175.8)^2 + (66.8 - 81.6)^2} = 20.16.$$

La distance de Manhattan entre Alice et Bob est

$$d(\text{Alice}, \text{Bob}) = |162.1 - 175.8| + |66.8 - 81.6| = 28.5.$$

La distance L_q n'est pas invariante aux changements d'échelle. Par exemple, si on multiplie toutes les composantes d'un vecteur par un facteur λ , la distance entre deux vecteurs change du facteur λ .

En pratique, on préfère travailler avec des variables standardisées. Ainsi, en notant, μ_i , la moyenne, et σ_i , l'écart-type de la variable i , la distance euclidienne avec des variables standardisées est donnée par :

$$d(x, y) = \sum_{i=1}^p \left\{ \frac{x_i - \mu_i}{\sigma_i} - \frac{y_i - \mu_i}{\sigma_i} \right\}^2 = \sum_{i=1}^p \left(\frac{x_i - y_i}{\sigma_i} \right)^2.$$

Propriété

La distance euclidienne avec des variables standardisées est invariante par changement d'échelle.

Preuve

Soit $\lambda \neq 0$ et soit X une variable aléatoire. On a $\mathbb{E}(\lambda X) = \lambda \mathbb{E}(X)$ et $\text{Var}(\lambda X) = \lambda^2 \text{Var}(X)$.
Donc

$$d(\lambda x, \lambda y) = \sum_{i=1}^p \left\{ \frac{\lambda x_i - \lambda \mu_i}{\lambda \sigma_i} - \frac{\lambda y_i - \lambda \mu_i}{\lambda \sigma_i} \right\}^2 = \sum_{i=1}^p \left(\frac{x_i - y_i}{\sigma_i} \right)^2 = d(x, y).$$

2 Notion de similarité

À l'opposé de la notion de distance, une **mesure de similarité** quantifie à quel point deux observations sont proches dans un espace donné. Ainsi, plus la similarité est grande, plus les observations sont proches.

Définition de mesure de similarité

Une fonction $s : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est une mesure de similarité sur un ensemble $\mathcal{X}$ si, pour tout $x, y \in \mathcal{X}$, les conditions suivantes sont vérifiées :

1. $s(x, y) \geq 0$;
2. $s(x, y) = s(y, x)$;
3. $s(x, x) = 1 \geq s(x, y)$.

Une distance peut se transformer en similarité en posant

$$s(x, y) = \frac{1}{1 + d(x, y)}.$$

Cette transformation garantit que plus la distance est grande, plus la similarité est faible. Toutefois, l'inverse n'est pas toujours possible car une mesure de similarité ne respecte pas forcément l'inégalité triangulaire. On peut aussi définir la dissemblance entre deux objets :

$$d^*(x, y) = 1 - s(x, y).$$

3 Cas de variables qualitatives

Lorsque l'on travaille avec des variables qualitatives, les distances numériques habituelles (comme les distances L_p) n'ont généralement pas de sens. Par exemple, si une variable prend ses valeurs dans l'ensemble

$$\mathcal{X} = \{\text{Rouge}, \text{Vert}, \text{Bleu}\},$$

alors il n'y a pas de sens à calculer la différence entre Bleu et Rouge, car ces modalités ne portent aucune structure numérique intrinsèque et n'ont aucune notion d'ordre ou d'écart.

Une mauvaise pratique consisterait à attribuer arbitrairement des valeurs numériques aux modalités (e.g. Rouge = 1, Vert = 2, Bleu = 3) ce qui introduirait un ordre artificiel entre elles. Cela risquerait de biaiser fortement les analyses.

3.1 Encodage 1 parmi K

Lorsque l'on veut utiliser un modèle se basant sur une notion de distance entre les observations (i.e. la plupart des modèles), on doit utiliser un encodage adapté. L'**encodage 1 parmi K** (*one-hot encoding*) consiste à encoder une variable qualitative à K modalités sous la forme d'un vecteur binaire de dimension K , dans lequel une seule entrée est à 1, les autres à 0. Ainsi, pour l'exemple de $\mathcal{X} = \{\text{Rouge}, \text{Vert}, \text{Bleu}\}$, on obtiendra l'encodage suivant : "Rouge" donne $(1, 0, 0)$, "Vert" donne $(0, 1, 0)$ et "Bleu" donne $(0, 0, 1)$.

Cette méthode d'encodage a l'avantage de ne pas introduire d'ordre artificiel entre les modalités. Cependant, si la variable a beaucoup de modalités, l'espace de représentation sera de grande dimension, ce qui peut nuire à l'efficacité de certaines méthodes d'analyse.

3.2 Définir une distance adaptée

Une fois les modalités encodées, on peut définir une distance entre deux observations de variables qualitatives.

La distance discrète (ou distance de Hamming)

Soit $\mathcal{X}$ un ensemble discret et soient x et y deux observations de X , la **distance discrète** est donnée par

$$d(x, y) = \begin{cases} 0, & \text{si } x = y, \\ 1, & \text{si } x \neq y \end{cases}.$$

Pour des vecteurs de variables qualitatives (e.g. la comparaison de plusieurs individus décrits par plusieurs caractéristiques), la distance discrète est la **somme des désaccords** entre les composantes :

$$d(x, y) = \sum_{i=1}^p \mathbb{1}(x_i \neq y_i),$$

où p est le nombre de variables.

Exemple

Prenons les caractéristiques de trois personnes.

TABLE 2 : Caractéristiques de trois personnes.

Nom	Couleur	Yeux	Cheveux
Alice	Rouge	Bleu	Blond
Bob	Vert	Bleu	Roux
Chris	Rouge	Vert	Blond

On calcule la distance entre deux personnes comme le nombre de caractéristiques différentes. Ainsi,

$$d(\text{Alice}, \text{Bob}) = 1 + 0 + 1 = 2,$$

$$d(\text{Alice}, \text{Chris}) = 0 + 1 + 0 = 1,$$

$$d(\text{Bob}, \text{Chris}) = 1 + 1 + 1 = 3.$$

Plutôt que de compter les différences, on peut aussi compter les accords et les normaliser :

$$s(x, y) = \frac{1}{p} \sum_{i=1}^p \mathbb{1}(x_i = y_i),$$

ce qui donne une mesure de similarité comprise entre 0 (aucun accord) et 1 (identique).

Exemple

En reprenant l'exemple précédent (cf. Table 2), on trouve les similarités suivantes :

$$s(\text{Alice}, \text{Bob}) = \frac{0 + 1 + 0}{3} = \frac{1}{3},$$

$$s(\text{Alice}, \text{Chris}) = \frac{1 + 0 + 1}{3} = \frac{2}{3},$$

$$s(\text{Bob}, \text{Chris}) = \frac{0 + 0 + 0}{3} = 0.$$

3.3 Distance de Jaccard

Lorsque le nombre de variables binaires est grand (e.g. dans le cas où un encodage 1 parmi K a été fait sur p variables qualitatives), la distance discrète n'est pas forcément très adaptée car le nombre d'accords risque d'être petit par rapport au nombre total de variables ($K \times p$ dans l'exemple précédent), ce qui va donner de petites distances dans tous les cas. Une des solutions est de se concentrer uniquement sur les attributs qui valent 1, car généralement, une variable binaire à 0 n'apporte pas spécialement d'information (en tout cas, moins qu'une variable binaire à 1). L'indice de Jaccard (*Intersection over Union*, IoU) a été introduit pour prendre cela en compte.

Définition : Indice de Jaccard

Considérons deux observations x et y de K variables binaires. Toutes les variables peuvent prendre les valeurs 0 et 1.

Définissons les quantités suivantes :

- M_{11} , le nombre de variables à 1 pour x et y ;
- M_{10} , le nombre de variables à 1 pour x et 0 pour y ;
- M_{01} , le nombre de variables à 0 pour x et 1 pour y ;
- M_{00} , le nombre de variables à 0 pour x et y .

Chaque variable binaire étant forcément comptée, soit dans M_{11} , soit dans M_{10} , soit dans M_{01} , soit dans M_{00} , leur somme est donc égale à K .

L'**indice de Jaccard** est défini comme

$$J(x, y) = \frac{M_{11}}{M_{10} + M_{01} + M_{11}} = \frac{M_{11}}{K - M_{00}}.$$

En faisant attention au cas où les deux observations ne sont constituées que de 0 (on prend $J(x, y) = 1$ dans ce cas), l'indice de Jaccard est une mesure de similarité.

Propriété : Distance de Jaccard

Pour deux observations x et y de K variables binaires, la **distance de Jaccard** est donnée par

$$d(x, y) = 1 - J(x, y).$$

Preuve

Pour montrer que la distance de Jaccard est bien une distance, on doit montrer les quatre propriétés des distances. Notons d'abord que la distance de Jaccard peut se réécrire comme

$$d(x, y) = \frac{M_{10} + M_{01}}{M_{01} + M_{10} + M_{11}}.$$

1. Tous les termes au numérateur et au dénominateur sont positifs, donc $d(x, y) \geq 0$.
2. Montrons que $d(x, y) = 0 \Leftrightarrow x = y$.

Supposons que $d(x, y) = 0$. Alors $M_{01} + M_{10} = 0$. Donc, il n'y a pas de variables qui valent 0 pour x et 1 pour y et inversement. Comme $M_{01} + M_{10} + M_{11} > 0$, on a $x = y$. Maintenant, supposons que $x = y$. Alors $M_{01} = M_{10} = 0$. Donc $d(x, y) = 0$.

3. On a que $d(x, y) = d(y, x)$ car l'indice de Jaccard est symétrique.
4. La preuve de l'inégalité triangulaire sera faite en exercice (cf. [TD](#))).

Exemple

Prenons un questionnaire de 5 questions fermées. Supposons que la réponse "Oui" soit encodée par 1 et la réponse "Non" soit encodée par 0.

TABLE 3 : Caractéristiques de deux personnes.

Nom	Q1	Q2	Q3	Q4	Q5
Alice	1	0	1	0	0
Bob	1	0	0	1	0

Pour la distance entre Alice et Bob, on a $M_{11} = 1$, $M_{10} = 1$, $M_{01} = 1$ et $M_{00} = 2$. Donc, la similarité de Jaccard est donnée par $J(\text{Alice}, \text{Bob}) = \frac{1}{3}$. Ainsi, la distance de Jaccard est $d(\text{Alice}, \text{Bob}) = 1 - J(x, y) = \frac{2}{3}$.