Analyse de données

Project d'analyse données

Un projet d'analyse de données se découpe en cinq étapes :

- 1. Définition des objectifs
- 2. Données
- 3. Élaboration et validation des modèles
- 4. Mise en oeuvre
- 5. Suivi de la performance et amélioration

Remarque

Dans ce cours, on s'intéressera principalement à l'élaboration et à la validation de modèles.

TODO: Planification d'un projet

Définition des objectifs

Est-ce que l'on veut : visualiser les données? explorer et émettre des hypothèses? tester? regrouper? comprendre? prédire?

Comment fait-on en pratique? On pose des questions! Tout d'abord, il faut clarifier les termes. Qui va utiliser le modèle et comment? Quelle est la population cible?

Examples

- 1. La Banque National du Canada veut lancer un nouveau produit d'épargne et souhaite mieux connaître ses clients pour prédire s'ils veulent l'acheter.
- 2. L'équipe de hockey des Canadiens de Montréal souhaite mieux connaître ses adversaires pour développer des nouvelles tactiques de jeu.
- 3. Pharmascience souhaite savoir si son nouveau médicament est efficace.

Données

- Inventaire et qualité
- Constitution de la base de données
- Exploration et traitement préliminaire

Qu'est-ce que l'on veut dire par qualité des données?

- Est-ce que les données sont représentatives de la population cible?
- Est-ce que les données permetternt de tirer des conclusions de causalité?
- Est-ce que les données sont fiables?

Source de données :

Quelques liens pour récupérer des données.

Nettoyage de données : cf R (importation, nettoyage, tidyverse, types de variables, retirer les doublons, uniformiser les modalités, vérifier le format des valeurs spéciales, pivot, opérateur pipe, jointure).

Exploration des données : modalités rares, modalités trop nombreuses, asymétrie, débalancement des classes, valeurs extrêmes ou aberrantes, variables fortement corrélées, valeurs manquantes.

Statistiques descriptives