# k-means

## Algorithme des k-moyennes :

- 1. On choisit le nombre de groupes K.
- 2. On partionne aléatoirement les n observations en K groupes.
- 3. On calcule le vecteur-moyenne pour chacun des K groupes, soit

$$\mu_k = \frac{1}{N_k} \sum_{i:C(i)=k} x_i, \quad k=1,\dots,K,$$

où  ${\cal N}_k$  est le nombre d'observations dans le group k.

- 4. On calcule la distance entre chaque observation et chacun des K vecteurs-moyennes.
- 5. On assigne chacune des n observations au groupe dont le vecteur-moyenne est le plus près.
- 6. On repète les étapes 3 à 5 jusqu'à ce qu'aucune observation ne soit réassignée à un nouveau groupe.

#### Example

Inconvénients des k-means :

- Sensible au choix des centroïdes initiaux (à l'initialisation).
- Il faut connaître le nombre de groupes.
- Nécessite une mesure de distance recalculée à chaque itération.
- Assez sensible aux valeurs extrêmes.

Expliciter chaque nconvénients et de potentielles solutions.

# k-médoides

On n'utilise plus le centre, mais l'observation qui minimise les distances dans chaque groupe. La médiane plutôt que la moyenne.

### Avantages:

- Permet d'intégrer des variables ordinales
- Robuste
- Permet de bien spécifier la matrix de distance

# Inconvénients :

— Il faut connaître le nombre de groupes.