

Corrigé - Rappels

Steven Golovkine

Automne 2026

Réponses

Exercice 1 — Combinaisons linéaires et matrice de covariance

1. La matrice est symétrique, son premier mineur principal vaut $4 > 0$ et son déterminant vaut $4 \times 9 - 1.5^2 = 33.75 > 0$. Le critère de Sylvester montre qu'elle est définie positive.
2. Les écarts-types sont 2 et 3, d'où $\rho_{XY} = 1.5/(2 \times 3) = 0.25$.
3. Avec $a = (2, -1)^\top$, $Z = a^\top (X, Y)^\top$. Ainsi,

$$E(Z) = a^\top \mu = 2 \times 2 - (-1) = 5,$$

$$\text{Var}(Z) = a^\top \Sigma a = 4 \text{Var}(X) + \text{Var}(Y) - 4 \text{Cov}(X, Y) = 19.$$

4. Pour $b = (1, 1)^\top$,

$$E(W) = b^\top \mu = 1, \quad \text{Var}(W) = b^\top \Sigma b = 16,$$

$$\text{et } \text{Cov}(Z, W) = a^\top \Sigma b = 0.5.$$

5. Une covariance nulle ne suffit généralement pas à établir l'indépendance. Elle l'implique toutefois pour un vecteur gaussien. Ici, la covariance calculée n'est d'ailleurs pas nulle.

Exercice 2 — Paradoxe des deux enfants

1. Le sexe de la cadette est indépendant de celui de l'aînée. La probabilité demandée vaut $1/2$.

2. Avant conditionnement, les quatre couples ordonnés FF, FG, GF et GG sont équiprobables. L'information « au moins un garçon » élimine seulement FF. Il reste trois possibilités, dont une seule GG : la probabilité vaut $1/3$.
3. Le choix aléatoire désigne un enfant précis. Conditionnellement au fait que celui-ci est un garçon, le sexe de l'autre reste indépendant : la réponse est $1/2$. Dans la question 2, aucune position n'est désignée et les familles mixtes possèdent deux ordres possibles.
4. La fille rencontrée est identifiée. Son jour de naissance ne renseigne pas sur le sexe de l'autre enfant, dont la probabilité d'être une fille reste $1/2$.
5. Chaque enfant possède 14 états sexe-jour. Parmi les $14^2 = 196$ couples, $196 - 13^2 = 27$ contiennent au moins une fille née vendredi. Parmi les $7^2 = 49$ couples de deux filles, $49 - 6^2 = 13$ satisfont cette condition. La probabilité vaut donc $13/27$, et non $1/2$.
6. Une probabilité conditionnelle dépend du mécanisme qui produit l'information. Les formulations « un enfant identifié », « au moins un » et « une réponse choisie par le parent » ne définissent pas le même événement. Sans protocole d'observation, le problème peut être ambigu.

Exercice 3 — Combinaisons linéaires et matrice de covariance

1. Sur 10000 personnes, on attend 200 personnes atteintes : 180 positives et 20 négatives. Parmi les 9800 personnes non atteintes, 490 sont faussement positives et 9310 négatives.
2. La probabilité marginale d'un positif vaut

$$P(+) = 0.02 \times 0.90 + 0.98 \times 0.05 = 0.067.$$

Par Bayes,

$$P(D|+) = \frac{0.018}{0.067} \approx 0.2687.$$

3. On obtient

$$P(\bar{D}|-) = \frac{0.98 \times 0.95}{0.98 \times 0.95 + 0.02 \times 0.10} = \frac{0.931}{0.933} \approx 0.9979.$$

4. La faible prévalence produit beaucoup plus de personnes non atteintes. Même un faible taux de faux positifs appliqué à ce grand groupe peut dépasser le nombre de vrais positifs.
5. Sous l'indépendance conditionnelle,

$$P(D|+, +) = \frac{0.02 \times 0.90^2}{0.02 \times 0.90^2 + 0.98 \times 0.05^2} \approx 0.8686.$$

6. Une cause commune, comme une interférence propre à l'échantillon, peut provoquer deux erreurs semblables. L'indépendance surestimerait alors l'information supplémentaire du second test.

Exercice 4 — Estimation par Monte-Carlo

La fonction suivante vectorise les n tests d'appartenance.

```
estimate_pi <- function(n) {  
  x <- runif(n, -1, 1)  
  y <- runif(n, -1, 1)  
  pi <- 4 * mean(x^2 + y^2 <= 1)  
  list(x = x, y = y, pi = pi)  
}
```

```
set.seed(2200)  
n <- 100000  
pi_hat <- estimate_pi(n)  
pi_hat$pi
```

Avec cette graine, $\hat{\pi} \approx 3.14284$. Pour éviter un graphique trop lourd, on peut n'afficher que les 5000 premiers points.

```
inside <- pi_hat$x^2 + pi_hat$y^2 <= 1  
keep <- seq_len(5000)  
plot(  
  pi_hat$x[keep], pi_hat$y[keep], asp = 1, pch = 16, cex = 0.35,  
  col = ifelse(inside[keep], "steelblue", "tomato"),  
  xlab = "x", ylab = "y"  
)  
theta <- seq(0, 2 * pi, length.out = 500)  
lines(cos(theta), sin(theta), lwd = 2)
```

La moyenne cumulée fournit toutes les estimations sans refaire les tirages.

```
pi_path <- 4 * cumsum(inside) / seq_len(n)  
grid <- unique(round(10^seq(1, 5, length.out = 100)))  
  
plot(  
  grid, abs(pi_path[grid] - pi), log = "xy",  
  type = "l", xlab = "Nombre de points",  
  ylab = "Erreur absolue"  
)
```

L'erreur n'est pas monotone : ajouter des points peut momentanément éloigner l'estimation de π . Son ordre typique diminue cependant comme $n^{-1/2}$. En effet, si $p = \pi/4$,

$$\text{Var}(\hat{\pi}) = 16 \frac{p(1-p)}{n}.$$

```

estimate_pi <- function(n) {
  x <- runif(n, -1, 1)
  y <- runif(n, -1, 1)
  4 * mean(x^2 + y^2 <= 1)
}
set.seed(2200)
estimates <- replicate(1000, estimate_pi(2000))
c(mean = mean(estimates), sd = sd(estimates))

p <- pi / 4
theoretical_sd <- 4 * sqrt(p * (1 - p) / 2000)
theoretical_sd

```

On obtient une moyenne d'environ 3.14175, un écart-type empirique de 0.03712 et une valeur théorique de 0.03672.

Pour le grand échantillon initial, un intervalle approché est

```

p_hat <- mean(inside)
se <- 4 * sqrt(p_hat * (1 - p_hat) / n)
pi_hat$pi + c(-1, 1) * qnorm(0.975) * se

```

Il vaut environ [3.1327, 3.1530]. Avec un petit n , l'approximation normale et le remplacement de p par $\hat{p}$ peuvent être médiocres ; un intervalle binomial pour p , ensuite multiplié par 4, est préférable.

Exercice 5 — Loi des gaz parfaits

Les deux vecteurs contiennent 30 valeurs sans donnée manquante. Le nuage est très proche d'une droite croissante.

```

plot(
  temperature, pressure, pch = 16,
  xlab = "Température (K)", ylab = "Pression (kPa)"
)

```

```

X <- cbind(intercept = 1, temperature = temperature)
Y <- pressure
beta <- solve(crossprod(X), crossprod(X, Y))
beta

```

Le calcul matriciel donne $\hat{\beta}_0 \approx 4.1676$ kPa et $\hat{\beta}_1 \approx 3.3150$ kPa/K.

```

fit <- lm(pressure ~ temperature)
coef(fit)

fitted_values <- drop(X %*% beta)
residuals <- Y - fitted_values
r_squared <- 1 - sum(residuals^2) / sum((Y - mean(Y))^2)
r_squared

```

Les coefficients coïncident avec ceux de 1m à l'arrondi près et $R^2 \approx 0.9980$. L'ordonnée à l'origine est la pression extrapolée à $T = 0$ K ; le modèle idéal prévoit zéro. La valeur estimée est faible au regard des pressions mesurées et son incertitude est importante, car zéro kelvin est très loin de la plage observée.

La pente théorique vérifie, lorsque P est exprimée en pascals, $\beta_1 = nR/V$. Avec $V = 10 \text{ dm}^3 = 0.01 \text{ m}^3$:

```
R <- 8.314
volume_m3 <- 10e-3
slope_pa <- beta[2] * 1000
n_moles <- slope_pa * volume_m3 / R
n_moles
```

On estime $n \approx 3.99$ moles.

```
plot(
  temperature, residuals, pch = 16,
  xlab = "Température (K)", ylab = "Résidu (kPa)"
)
abline(h = 0, lty = 2)
```

Un excellent alignement confirme la compatibilité des données avec la loi sur cette plage. Il ne vérifie pas indépendamment l'étalonnage des instruments, la constance réelle du volume et de la quantité de matière, ni l'absence de variables confondantes. L'extrapolation jusqu'à 0 K reste particulièrement fragile.

Exercice 6 — Loi d'Ohm, covariance et ajustement linéaire

1. Les moyennes sont $\bar{A} = 0.9857$ A et $\bar{V} = 20.6429$ V.
2. Avec le diviseur $n = 7$,

$$\text{Var}(A) \approx 0.23837, \quad \text{Var}(V) \approx 106.5396, \quad \text{Cov}(A, V) \approx 5.03918.$$

L'emploi du diviseur $n - 1$ multiplierait les trois quantités par $7/6$; il ne changerait donc ni la corrélation ni la pente.

3. La corrélation vaut environ 0.99996. Le nuage est presque parfaitement aligné et croissant. Une corrélation, même très élevée, ne suffit toutefois pas à établir seule une causalité ou la validité d'une loi physique.
4. On obtient

$$R = \frac{5.03918}{0.23837} \approx 21.1404 \text{ ohms},$$

puis $\beta_0 = \bar{V} - R\bar{A} \approx -0.1955$ V. Le modèle ajusté est donc $\hat{V} = -0.1955 + 21.1404A$.

5. Sans constante, la pente minimise $\sum_i (V_i - RA_i)^2$ et vaut

$$\hat{R}_0 = \frac{\sum_i A_i V_i}{\sum_i A_i^2} \approx 20.9811 \text{ ohms.}$$

Les deux valeurs sont proches, car l'ordonnée à l'origine libre est déjà voisine de zéro.

6. Les rapports observés sont approximativement 20.00, 20.80, 20.78, 21.10, 20.92, 21.08 et 21.00. Les résidus du modèle avec constante ont une somme nulle et une somme des carrés d'environ 0.0643. Les écarts proviennent notamment du bruit de mesure, des arrondis et des limites du modèle idéal ; diviser observation par observation n'agrège pas le bruit de la même façon que les moindres carrés.

Exercice 7 — Loi des grands nombres et théorème central limite

Une matrice stockant une répétition par ligne permet de vectoriser les moyennes.

```
simulate_exponential <- function(n, B = 5000, rate = 2) {
  samples <- matrix(rexp(B * n, rate), nrow = B, ncol = n)
  means <- rowMeans(samples)
  sds <- apply(samples, 1, sd)

  list(
    means = means,
    sds = sds,
    z = sqrt(n) * (means - 0.5) / 0.5
  )
}
```

```
set.seed(2200)
sizes <- c(5, 30, 100)
simulations <- lapply(sizes, simulate_exponential)
names(simulations) <- sizes
par(mfrow = c(1, 3))
for (n in sizes) {
  z <- simulations[[as.character(n)]]$z
  hist(
    z, probability = TRUE, breaks = 40,
    main = paste("n =", n), xlab = "z"
  )
  curve(dnorm(x), add = TRUE, col = 2, lwd = 2)
}
par(mfrow = c(1, 1))
```

Pour $n = 5$, l'histogramme conserve une asymétrie à droite. Celle-ci diminue pour $n = 30$ et $n = 100$, conformément au théorème central limite.

```
diagnostics <- t(vapply(simulations, function(out) {
  c(
    mean = mean(out$z),
```

```

    variance = var(out$z),
    q025 = unname(quantile(out$z, 0.025)),
    q975 = unname(quantile(out$z, 0.975))
  )
}, numeric(4)))
diagnostics

```

Les cibles sont 0, 1, -1.96 et 1.96 . Elles sont approchées de mieux en mieux lorsque n augmente ; des écarts de simulation d'ordre $B^{-1/2}$ subsistent.

```

known_sd_coverage <- vapply(seq_along(sizes), function(i) {
  n <- sizes[i]
  means <- simulations[[i]]$means
  half_width <- 1.96 * 0.5 / sqrt(n)
  mean(means - half_width <= 0.5 &
    0.5 <= means + half_width)
}, numeric(1))

estimated_sd_coverage <- vapply(seq_along(sizes), function(i) {
  n <- sizes[i]
  out <- simulations[[i]]
  half_width <- 1.96 * out$sds / sqrt(n)
  mean(out$means - half_width <= 0.5 &
    0.5 <= out$means + half_width)
}, numeric(1))

data.frame(
  n = sizes,
  known_sd_coverage,
  estimated_sd_coverage
)

```

Les couvertures se rapprochent de 95% avec n . Pour un petit échantillon, la normalité approximative est moins précise et l'estimation de σ ajoute de la variabilité. Un intervalle fondé sur la loi exacte de la somme des exponentielles ou une méthode adaptée à l'asymétrie peut alors être préférable.