
Laboratoire - ACP

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Compréhension de l'ACP

Soit le vecteur aléatoire $X = (X_1, X_2, X_3, X_4)^\top$, d'espérance μ et de matrice de variance-covariance Σ , avec

$$\mu = \begin{pmatrix} 0 \\ 1 \\ -1 \\ 0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 9 & 1 & -1 & 2 \\ 1 & 4 & -1 & 1 \\ -1 & -1 & 16 & 0 \\ 2 & 1 & 0 & 9 \end{pmatrix}.$$

Les valeurs propres de Σ et des vecteurs propres unitaires associés sont, à l'arrondi près,

$$\lambda_1 = 16.27, \quad \alpha_1 = (0.165, 0.098, -0.980, 0.059)^\top,$$

$$\lambda_2 = 11.12, \quad \alpha_2 = (0.665, 0.169, 0.171, 0.707)^\top,$$

$$\lambda_3 = 6.95, \quad \alpha_3 = (0.718, -0.017, 0.077, -0.691)^\top,$$

$$\lambda_4 = 3.67, \quad \alpha_4 = (0.118, -0.981, -0.070, 0.139)^\top.$$

1. Trouver une combinaison linéaire de X_1, X_2, X_3 et X_4 dont la variance vaut 6.95.
2. On pose $Z = a_0 + a_1X_1 + a_2X_2 + a_3X_3 + a_4X_4$, avec $\sum_{j=1}^4 a_j^2 = 1$. Déterminer les coefficients pour que Z soit centrée et de variance maximale. Donner cette variance et la covariance entre Z et la combinaison trouvée à la question précédente.
3. Donner une matrice diagonale M telle que $M\Sigma M = R$, où R est la matrice de corrélation de X .

Exercice 2 — Reconstruction d'une matrice de covariance

Soit $X = (X_1, X_2, X_3)^\top$ un vecteur aléatoire de matrice de variance-covariance Σ . Ses valeurs propres sont 3, 2 et 1, et des vecteurs propres unitaires associés sont respectivement

$$v_1 = \left(0, -\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^\top, \quad v_2 = (1, 0, 0)^\top, \quad v_3 = \left(0, \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^\top.$$

Les variables X_1 , X_2 et X_3 représentent respectivement la circonférence du poignet droit, un score de capacité pulmonaire et l'indice de masse corporelle.

1. Les médecins souhaitent construire un score $C = c_1X_1 + c_2X_2 + c_3X_3$ de variance maximale sous la contrainte $\sum_{j=1}^3 c_j^2 = 1$. Déterminer les coefficients et la variance maximale.
2. Quelle proportion de la variabilité totale est capturée par C ?
3. Retrouver Σ à partir de sa décomposition spectrale.

Exercice 3 — Scores, corrélations et qualité de représentation en ACP

Trois variables centrées et réduites ont pour matrice de corrélation

$$R = \begin{pmatrix} 1 & 0.8 & 0 \\ 0.8 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Ses valeurs propres décroissantes et des vecteurs propres unitaires associés sont

$$\lambda_1 = 1.8, \quad a_1 = \frac{1}{\sqrt{2}}(1, 1, 0)^\top,$$

$$\lambda_2 = 1, \quad a_2 = (0, 0, 1)^\top,$$

$$\lambda_3 = 0.2, \quad a_3 = \frac{1}{\sqrt{2}}(1, -1, 0)^\top.$$

On note $Y_k = a_k^\top X$ la composante principale k .

1. Écrire explicitement les trois composantes principales et vérifier que leur somme de variances vaut la variance totale.
2. Montrer que, pour une ACP sur variables réduites,

$$\text{Corr}(X_j, Y_k) = \sqrt{\lambda_k} a_{jk}.$$

3. Calculer les coordonnées des trois variables dans le cercle des corrélations sur les axes 1 et 2.
4. On définit la contribution de la variable j à l'axe k par a_{jk}^2 . Calculer les contributions aux deux premiers axes et vérifier qu'elles somment à 1 sur chaque axe.
5. Calculer le cosinus carré de chaque variable avec le premier plan, défini comme la somme des carrés de ses corrélations avec Y_1 et Y_2 .
6. Pour l'individu centré et réduit $z = (1, -1, 2)^\top$, calculer ses trois scores, sa reconstruction sur les deux premiers axes et son erreur quadratique de reconstruction.
7. Que devient l'ensemble de ces résultats si l'on remplace a_1 par $-a_1$?

Exercice 4 — Individus et variables supplémentaires en ACP

Une ACP a été ajustée sur les trois variables actives centrées et réduites de l'exercice 3. Une variable quantitative supplémentaire standardisée W possède avec les variables actives le vecteur de corrélations

$$r_W = (0.6, 0.6, 0)^\top.$$

Elle n'a pas participé au calcul des axes.

1. Expliquer pourquoi l'ajout de W comme variable supplémentaire ne modifie ni les vecteurs propres ni les valeurs propres de l'ACP active.
2. Montrer que sa corrélation avec la composante Y_k vaut

$$\text{Corr}(W, Y_k) = \frac{r_W^\top a_k}{\sqrt{\lambda_k}},$$

puis calculer ses coordonnées sur les trois axes.

3. Les moyennes des variables actives sont $(10, 20, 30)$ et leurs écarts-types $(2, 5, 10)$. Projeter comme individu supplémentaire $x_{\text{sup}} = (12, 15, 50)^\top$.
4. Pourquoi faut-il employer les moyennes, écarts-types et axes de l'analyse initiale plutôt que les recalculer après l'arrivée de cet individu ?
5. Comment projeter un individu dont une variable active est manquante ? Pourquoi n'existe-t-il pas de projection exacte sans convention supplémentaire ?
6. Une variable qualitative supplémentaire décrit trois groupes. Que peut-on représenter sur le plan factoriel sans rendre l'ACP supervisée ?
7. Que changerait l'inclusion de W parmi les variables actives ?

Exercice 5 — Combien de composantes conserver ?

Une ACP centrée et réduite de $p = 8$ variables produit les valeurs propres

$$(3.1, 1.6, 1.0, 0.8, 0.6, 0.4, 0.3, 0.2).$$

1. Calculer les proportions de variance expliquée et leurs cumuls.
2. Combien d'axes faut-il conserver pour atteindre au moins 80% de variance expliquée ?
3. Appliquer le critère de Kaiser. Discuter la convention pour une valeur propre exactement égale à 1.
4. Une analyse parallèle fournit comme valeurs propres moyennes sous le modèle nul

$$(1.35, 1.22, 1.13, 1.05, 0.98, 0.91, 0.84, 0.77).$$

Combien d'axes suggère-t-elle de retenir ?

5. Calculer l'erreur minimale de reconstruction, exprimée comme variance résiduelle totale, lorsque l'on conserve deux puis quatre axes.
6. Pourquoi les critères de variance cumulée, de Kaiser, d'éboulis et d'analyse parallèle peuvent-ils conduire à des choix différents ?
7. Adapter le critère de choix aux objectifs suivants : visualisation, compression, débruitage et prédiction d'une réponse externe.

Exercice 6 — ACP de caractéristiques musicales Spotify

Le fichier `spotify.csv` fourni avec le devoir contient 1000 morceaux et dix genres musicaux. Chaque ligne comprend l'artiste, le titre, le genre et neuf caractéristiques numériques :

- `danceability`, `energy`, `loudness` et `speechiness` ;
- `acousticness`, `instrumentalness` et `liveness` ;
- `valence` et `tempo`.

Les variables comprises entre 0 et 1 sont des indices audio ; `loudness` est mesurée en décibels et `tempo` en battements par minute.

1. Importer les données, vérifier les dimensions, les types et les valeurs manquantes. Justifier une ACP centrée et réduite sur les neuf variables.
2. Ajuster l'ACP et donner la proportion de variance expliquée par chacun des trois premiers axes, puis leur cumul.
3. Tracer l'éboulis des valeurs propres et le premier plan factoriel. Colorer les morceaux selon `track_genre`, sans utiliser cette variable pour ajuster les axes.
4. À partir des coefficients des deux premiers axes, proposer une interprétation. Rappeler pourquoi le signe d'un axe n'a pas de sens propre.
5. Un nouveau morceau possède, dans l'ordre des neuf variables,

$$(0.676, 0.885, -8.482, 0.100, 0.0169, 0.694, 0.0909, 0.0954, 145)^\top.$$

Le projeter sur les trois premiers axes en réutilisant exactement les moyennes et écarts-types de l'ACP.

6. Comparer ses coordonnées aux centroïdes des dix genres dans l'espace des trois premiers axes. Proposer un genre plausible et expliquer pourquoi ce résultat n'est pas une validation supervisée.

Exercice 7 — Évaluer la stabilité d'une ACP par bootstrap

Le jeu `USArrests` comporte quatre variables pour 50 États américains.

1. Réaliser une ACP centrée et réduite et conserver ses deux premières directions comme référence.
2. Tirer 1000 échantillons bootstrap de 50 lignes. Recalculer entièrement la standardisation et l'ACP dans chaque échantillon.
3. Aligner le signe de chaque direction bootstrap sur la direction de référence, puis construire des intervalles empiriques à 95% pour les coefficients des deux premiers axes.
4. Calculer, pour chaque réplique, le plus grand angle principal entre les sous-espaces bidimensionnels de référence et bootstrap. Pourquoi cette quantité est-elle insensible aux signes et aux rotations internes ?
5. Réaliser une analyse laisser-un-État-dehors. Identifier les États dont le retrait fait le plus tourner le premier axe.
6. Comparer l'incertitude des axes individuels à celle du premier plan.
7. Pourquoi ce bootstrap constitue-t-il surtout une étude de sensibilité, et non nécessairement une inférence vers une population aléatoire d'États ?

Exercice 8 — Coquillages : conduire et interpréter une ACP

Le jeu de données `abalone.csv` contient 4177 coquillages. Pour chaque coquillage, on dispose du genre, de sept mesures physiques et du nombre d'anneaux, utilisé comme indicateur de l'âge.

1. Importer les données. Identifier les variables quantitatives et qualitatives, rechercher les valeurs manquantes et produire, pour chaque variable quantitative, la moyenne, l'écart-type, le minimum et le maximum. Repérer les valeurs qui méritent une vérification.
2. Réaliser une ACP centrée et réduite sur les huit variables quantitatives. Le genre sera conservé comme variable qualitative supplémentaire : il ne doit pas participer à la construction des axes.
3. Comparer trois règles de choix du nombre d'axes : critère de Kaiser, coude de l'éboullis et seuils de variance expliquée de 90% et 95%.
4. Calculer les contributions des variables aux trois premiers axes. Quelles sont les deux variables qui contribuent le plus au deuxième axe ?
5. Calculer les contributions des individus. Quelles sont les deux observations qui contribuent le plus au troisième axe ? Revenir aux données brutes pour comprendre pourquoi.
6. Interpréter le premier axe et calculer la proportion de variance expliquée par les trois premiers axes. Comparer également les coordonnées moyennes des trois genres sur les deux premiers axes.
7. Expliquer pourquoi la standardisation est, ou non, pertinente dans ce contexte. Comparer brièvement avec une ACP seulement centrée.