Laboratoire - Arbres de décision

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Construction du premier embranchement d'un arbre

On cherche à prédire une réponse binaire Y à partir de trois variables binaires. Les tableaux croisés sont :

	$Y=1$	$Y=0$
$X_1=1$	5	5
$X_1=0$	5	5

	$Y=1$	$Y=0$
$X_2=1$	10	0
$X_2=0$	0	10

	$Y=1$	$Y=0$
$X_3=1$	3	9
$X_3=0$	7	1

Pour un embranchement, on définit le critère après coupure comme la moyenne pondérée des impuretés des deux feuilles.

1. Calculer le taux d'erreur de classification après un embranchement sur chacune des trois variables.
2. Calculer l'indice de Gini pondéré correspondant.
3. Calculer l'entropie pondérée correspondante.
4. Quelle variable faut-il choisir pour le premier embranchement ?
5. Pour l'arbre à deux feuilles ainsi obtenu, calculer $R_\alpha(T) = R(T) + \alpha M(T)$ avec le taux d'erreur R, le nombre de feuilles M et $\alpha = 0.5$. Comparer ce coût à celui de l'arbre réduit à sa racine.

Exercice 2 — Construire manuellement un arbre de classification

On observe huit individus décrits par deux variables quantitatives :

Observation	1	2	3	4	5	6	7	8
Variable 1	241	396	257	259	156	193	438	356
Variable 2	96	121	125	94	68	62	133	125
Classe	A	A	A	A	B	B	A	B

Pour un nœud contenant des proportions p_A et p_B, l'indice de Gini vaut $G = 1 - p_A^2 - p_B^2$.

1. Calculer l'indice de Gini du nœud racine.
2. La première coupure est « Variable $1 < 300$ ». Calculer l'indice de Gini dans chacun des deux nœuds enfants.
3. Calculer la diminution pondérée de l'indice de Gini produite par cette coupure.
4. Dans le nœud « Variable $1 < 300$ », effectuer une seconde coupure « Variable $2 < 80$ ». Dessiner l'arbre obtenu et décrire la partition du plan $(\text{Variable } 1, \text{Variable } 2)$.
5. Classer une nouvelle observation dont les coordonnées sont $(250, 110)$.

Exercice 3 — Choix d'une coupure dans un arbre de régression

Six observations, déjà ordonnées selon une variable X, ont pour réponses

$$y = (1, 1, 2, 8, 9, 9).$$

Un arbre de régression prédit dans chaque feuille la moyenne des réponses et choisit la coupure qui minimise la somme des carrés résiduels (SCR).

1. Calculer la moyenne et la SCR du nœud racine.
2. Calculer la SCR après une coupure entre les troisième et quatrième observations.
3. Calculer la SCR après une coupure entre les deuxième et troisième observations.
4. Quelle coupure choisir ? Donner les deux prédictions terminales et la réduction de SCR obtenue.

Exercice 4 — Élagage par coût-complexité

Quatre sous-arbres emboîtés ont les taux d'erreur d'apprentissage et nombres de feuilles suivants :

Arbre	$R(T)$	$M(T)$
T_4	0.10	4
T_3	0.13	3
T_2	0.18	2
T_1	0.32	1

On minimise $R_\alpha(T) = R(T) + \alpha M(T)$.

1. Quel arbre minimise le critère pour $\alpha = 0.04$?
2. Calculer les valeurs de α auxquelles deux arbres successifs ont le même coût.
3. Décrire l'arbre optimal en fonction de $\alpha \geq 0$, en signalant les égalités aux points de rupture.
4. Pourquoi α doit-il être choisi sur des données de validation ou par validation croisée plutôt que par l'erreur d'apprentissage seule ?

Exercice 5 — Jus d'orange : ajuster et élaguer un arbre

Le jeu de données « OJ » de la librarie R, ISLR, contient 1070 achats de jus d'orange. La réponse « Purchase » indique le choix entre les marques « CH » et « MM », et les dix-sept autres variables décrivent notamment les prix, les promotions et la fidélité du client.

1. Créer, avec une graine fixée, un échantillon d'apprentissage de 800 observations et réserver les 270 restantes pour le test.
2. Ajuster un arbre de classification complet. Calculer son taux d'erreur d'apprentissage.
3. Représenter l'arbre, compter ses feuilles et interpréter une feuille à partir de son effectif, de sa distribution de classes et de son impureté.
4. Calculer la matrice de confusion et le taux d'erreur sur le test.
5. Utiliser une validation croisée à cinq blocs et le chemin coût-complexité pour choisir le paramètre d'élagage sans consulter le test. Combien de feuilles possède l'arbre retenu ?
6. Comparer les erreurs d'apprentissage et de test des arbres complet et élagué. Interpréter l'écart.

Exercice 6 — Réclamations Rakuten : ajuster et élaguer un arbre

Le fichier `rakuten.csv` contient une cible binaire `CLAIM_TYPE` et douze variables décrivant une transaction et son expédition.

1. Importer les données, étudier la cible, les types de variables, les valeurs manquantes et les modalités rares.
2. Construire une partition aléatoire à 70% pour l'apprentissage et 30% pour la validation. Mettre en place une règle apprise sur l'entraînement pour regrouper les modalités rares et inconnues sous `OTHER`. Pourquoi cette étape est-elle nécessaire ?
3. Ajuster un arbre avec ses paramètres par défaut. Calculer les précisions sur le jeu d'apprentissage et le jeu de validation ainsi que le taux d'erreur du nœud numéroté 3.
4. Ajuster un arbre maximal avec `minsplit = 2`, `minbucket = 1` et `cp = 0`. Comparer sa taille et ses erreurs à celles de l'arbre par défaut.
5. Élager l'arbre maximal sur une grille de valeurs de `cp`. Tracer les erreurs d'apprentissage et de validation en fonction de `cp`, puis choisir la complexité sans utiliser le jeu de validation plus d'une fois.