Laboratoire
Classification hiérarchique

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Classification ascendante hiérarchique

On considère la matrice de dissimilarité entre quatre observations :

Observation	1	2	3	4
1	0	0.30	0.40	0.70
2	0.30	0	0.50	0.80
3	0.40	0.50	0	0.45
4	0.70	0.80	0.45	0

1. Construire le dendrogramme obtenu par classification ascendante hiérarchique avec le lien simple, ou méthode du plus proche voisin. Indiquer la hauteur de chaque fusion.
2. Reprendre le calcul avec le lien complet, ou méthode du voisin le plus distant.
3. Quelle partition obtient-on en coupant chacun des deux arbres pour conserver exactement deux groupes ?
4. Donner, pour chaque arbre, un ordre différent des feuilles qui représente le même dendrogramme.

Exercice 2 — CAH sur huit observations

On considère la matrice de distances entre huit observations. Deux entrées ont été masquées par les lettres A et B.

Obs.	1	2	3	4	5	6	7	8
1	0	1.464	0.997	1.346	1.336	1.447	1.711	1.785
2	1.464	0	1.365	0.986	2.761	2.523	0.589	0.898
3	0.997	1.365	0	1.067	2.275	1.708	1.866	1.976
4	1.346	0.986	1.067	0	2.517	1.694	1.528	B
5	1.336	A	2.275	2.517	0	1.196	2.881	2.034
6	1.447	2.523	1.708	1.694	1.196	0	2.977	2.066
7	1.711	0.589	1.866	1.528	2.881	2.977	0	0.969
8	1.785	0.898	1.976	0.546	2.034	2.066	0.969	0

1. Déterminer A et B.
2. Construire la classification ascendante hiérarchique avec le lien simple, ou méthode du plus proche voisin. Indiquer la hauteur de chaque fusion et dessiner le dendrogramme.
3. Reprendre le calcul avec le lien complet, ou méthode du voisin le plus distant.
4. Couper chacun des deux arbres afin d'obtenir deux groupes. Donner les deux partitions.
5. Pour chacune de ces partitions, calculer la silhouette de l'observation 4.
6. Donner un ordre différent des feuilles qui conserve l'interprétation de chaque dendrogramme.

Exercice 3 — Comparer trois critères de liaison

À une étape d'une classification ascendante, il reste trois groupes A, B et C, chacun de taille 2. Les dissimilarités entre paires d'observations appartenant à deux groupes différents sont :

Paire de groupes	Dissimilarités croisées
A, B	$(1, 5, 6, 10)$
A, C	$(2, 2.5, 3.5, 4)$
B, C	$(3, 3.1, 3.3, 3.5)$

1. Calculer les dissimilarités entre groupes avec le lien simple, le lien complet et le lien moyen.
2. Quelle paire fusionne en premier selon chacun des trois critères ?
3. Une seule dissimilarité de la paire (A, B) vaut 1, tandis que les autres sont grandes. Expliquer pourquoi cet exemple illustre le phénomène de chaînage du lien simple.

Exercice 4 — Critère de Ward et hausse d'inertie

Trois groupes A, B et C ont les caractéristiques suivantes :

Groupe	Effectif	Centroïde	Inertie interne
A	4	$(0,0)^\top$	6
B	2	$(3,1)^\top$	2
C	3	$(1,4)^\top$	5

Pour des données euclidiennes, la hausse d'inertie provoquée par la fusion de deux groupes est

$$\Delta(A,B) = \frac{n_A n_B}{n_A + n_B} \|\mu_A - \mu_B\|^2.$$

1. Calculer la hausse d'inertie associée à chacune des trois fusions possibles et indiquer celle que choisit Ward.
2. Calculer le centroïde et l'inertie interne du groupe fusionné.
3. Calculer la hausse d'inertie de la fusion ultérieure avec le troisième groupe.
4. Démontrer la formule de $\Delta(A,B)$ à partir de la décomposition de l'inertie autour du centroïde fusionné.

Exercice 5 — Arrestations aux États-Unis : CAH et standardisation

Le fichier `USArrests.csv` contient, pour chacun des 50 États américains, trois taux d'arrestation et la proportion de population urbaine. Les variables sont `Murder`, `Assault`, `UrbanPop` et `Rape`.

1. Importer les données. Vérifier leurs dimensions, leur type et l'absence de valeurs manquantes. Comparer les échelles des quatre variables.
2. Calculer les distances euclidiennes sur les données brutes, puis effectuer une classification ascendante hiérarchique avec le lien simple. Tracer le dendrogramme et le couper en trois groupes.
3. Lister les États de chaque groupe et calculer leurs profils moyens dans les unités initiales.
4. Refaire toute l'analyse après centrage-réduction des quatre variables.
5. Comparer les partitions. La standardisation est-elle justifiée ? Que révèle la taille des groupes sur le comportement du lien simple ?

Exercice 6 — Préférences musicales : classification ascendante et DIANA

Le fichier `musique.csv` contient neuf notes musicales `m1` à `m9` et quelques variables descriptives pour 47 personnes.

1. Importer le fichier, sélectionner les neuf notes et utiliser l'identifiant `id` comme nom de ligne. Vérifier les valeurs manquantes et les échelles.
2. Construire une CAH en distance euclidienne avec le lien moyen. Tracer le dendrogramme et obtenir six groupes.
3. Construire une classification descendante avec l'algorithme DIANA du paquet `cluster`, puis la couper également en six groupes. DIANA ne possède pas de paramètre de « lien moyen » : sa règle de division est propre à l'algorithme.
4. Calculer les silhouettes globale et par groupe pour les deux partitions. Décrire les groupes au moyen de leurs profils moyens.
5. Comparer les deux partitions sans supposer que leurs numéros de groupe ont la même signification.