Laboratoire - Analyse de Fisher

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Compréhension de l'analyse discriminante

On cherche à prédire l'appartenance de 80 observations à l'un de trois groupes à partir de cinq variables $X_1, ..., X_5$. Les moyennes par groupe sont les suivantes.

Groupe	$\overline{X}_1$	$\overline{X}_2$	$\overline{X}_3$	$\overline{X}_4$	$\overline{X}_5$
1	-0.155	0.202	-0.003	-0.909	-0.952
2	0.227	0.050	0.091	0.067	0.084
3	0.505	-0.313	-0.092	0.475	0.776

Les matrices de sommes de carrés totale, intragroupe et intergroupe vérifient $S = W + B$. Trois coefficients, notés u, v et w, ont été masqués :

$$S = \begin{pmatrix} 62.803 & u & -4.472 & -0.336 & 10.369 \\ u & 81.039 & 26.438 & -4.621 & 7.088 \\ -4.472 & 26.438 & 80.627 & 12.644 & -6.670 \\ -0.336 & -4.621 & 12.644 & 85.557 & 30.721 \\ 10.369 & 7.088 & -6.670 & 30.721 & 88.443 \end{pmatrix},$$

$$W = \begin{pmatrix} 56.401 & 10.815 & -3.671 & -13.815 & -6.382 \\ 10.815 & 76.904 & 25.491 & 5.372 & 19.919 \\ -3.671 & 25.491 & 80.198 & 13.934 & -4.656 \\ -13.815 & 5.372 & 13.934 & 56.705 & v \\ -6.382 & 19.919 & -4.656 & v & 44.591 \end{pmatrix},$$

$$B = \begin{pmatrix} 6.402 & -4.934 & -0.800 & 13.479 & 16.752 \\ -4.934 & 4.135 & 0.947 & w & -12.832 \\ -0.800 & 0.947 & 0.429 & -1.290 & -2.015 \\ 13.479 & w & -1.290 & 28.853 & 35.364 \\ 16.752 & -12.832 & -2.015 & 35.364 & 43.852 \end{pmatrix}.$$

Les deux valeurs propres non nulles de $S^{-1}B$ sont 0.751 et 0.011. Des vecteurs propres unitaires associés sont

$$a_1 = (-0.40, 0.37, -0.09, -0.44, -0.71)^\top,$$

$$a_2 = (0.08, -0.65, -0.28, -0.64, 0.29)^\top.$$

1. Calculer u, v et w.
2. Quelle proportion du pouvoir discriminant total est portée par la première fonction discriminante ?
3. On classe une observation sur le premier axe en l'affectant au groupe dont le centre projeté $a_1^\top \overline{X}_k$ est le plus proche de son score. Dans quel groupe classe-t-on $x = (-0.5, 0.5, 0, 1, 1)^\top$?

Exercice 2 — Deux formulations du quotient de Fisher

Soient W une matrice intragroupe définie positive, B une matrice intergroupe positive et $S = W + B$. Supposons que

$$Ba = \gamma W a, \quad a \neq 0.$$

1. Montrer que a est aussi vecteur propre de $S^{-1}B$ et exprimer sa valeur propre λ en fonction de γ.
2. Donner la relation inverse et expliquer pourquoi $0 \leq \lambda < 1$.
3. Transformer les valeurs $\lambda_1 = 0.751$ et $\lambda_2 = 0.011$ de la question 1 en quotients de Fisher γ_1 et γ_2.
4. Justifier qu'il existe au plus $K - 1$ axes discriminants non nuls pour K groupes.

Exercice 3 — Calculer Fisher à la main et comparer aux plus proches voisins

On observe les six individus suivants :

Indice	x_1	x_2	Classe
1	0	0	A
2	2	0	A
3	1	1	A
4	3	2	B
5	5	2	B
6	4	3	B

1. Calculer les moyennes, la matrice intragroupe W et la covariance commune estimée $S_p = \frac{W}{6-2}$.
2. Déterminer une direction de Fisher dont la première coordonnée vaut 1, orientée de A vers B. Calculer la valeur du quotient utilisant W.
3. Avec des a priori et des coûts égaux, classer par le milieu des moyennes projetées. Donner le seuil et classer $x_0 = (3, 1)^\top$.
4. Classer le même point par 1-NN et 3-NN avec les distances euclidiennes dans les coordonnées d'origine. Expliquer les accords et les différences.

Exercice 4 — Covariance singulière et direction de Fisher régularisée

On dispose de n observations réparties en C classes non vides et de p variables. La matrice W est la somme des produits extérieurs des résidus centrés dans leur classe.

1. Montrer que $\mathrm{rang}(W) \leq \min(p, n - C)$. Donner une situation où W est nécessairement singulière.
2. Considérer $W = \mathrm{diag}(1, 0)$ et $d = (1, 1)^\top$. Que devient le quotient de Fisher pour des directions tendant vers $(0, 1)^\top$?
3. Pour $\lambda > 0$, remplacer W par $W_\lambda = W + \lambda I$. Calculer $a_\lambda = W_\lambda^{-1} d$ et décrire sa direction lorsque λ tend vers zéro puis vers l'infini.
4. Pourquoi une séparation parfaite dans l'échantillon ne garantit-elle pas une bonne généralisation ? Comment choisir λ et traiter les unités des variables ?

Exercice 5 — Crabes : comparer LDA, k-NN et k-NN sur les axes de Fisher

Le jeu `MASS::crabs` contient cinq mesures morphologiques, en millimètres, pour 200 crabes. On cherche à prédire les quatre combinaisons de forme colorée (`sp`, bleue ou orange) et de sexe (`sex`), chacune représentée par 50 observations. Les prédicteurs sont `FL`, `RW`, `CL`, `CW` et `BD`. Les variables `sp`, `sex` et `index` sont exclues des prédicteurs.

1. Réserver 15 observations par classe pour le test. Sur les 140 observations restantes, construire cinq plis stratifiés communs à toutes les méthodes. Employer des a priori LDA égaux à $\frac{1}{4}$.
2. Comparer la LDA, k-NN dans les cinq variables standardisées et k-NN dans les q premiers axes de Fisher, avec $q \in \{1, 2, 3\}$. Pour k-NN, tester $k \in \{1, 3, 5, 7, 11, 15, 21\}$ avec un vote uniforme.
3. Réestimer la standardisation et la projection de Fisher à l'intérieur de chaque pli. Choisir les hyperparamètres de chaque méthode par l'erreur hors pli ; à égalité, préférer le plus petit q, puis le plus grand k.
4. Réajuster les trois procédures sur l'apprentissage complet et calculer sur le test les matrices de confusion, le taux d'erreur et l'exactitude équilibrée. Représenter l'apprentissage sur les deux premiers axes.
5. Interpréter l'effet de la projection sur les voisins. Les différences observées permettent-elles d'affirmer une supériorité générale ?

Exercice 6 — Positions NFL : construire et appliquer l'analyse de Fisher

Le fichier `nfl.csv` contient les résultats de joueurs évalués avant la sélection NFL. On s'intéresse aux quarts-arrières (`QB`), aux joueurs de ligne offensive (`OL`) et aux joueurs de ligne défensive (`DL`). Les prédicteurs sont la taille `Ht` et le poids `Wt`. Dans tout l'exercice, les a priori des classes considérées sont égaux et les erreurs ont le même coût.

1. Importer les données, examiner les valeurs manquantes puis conserver les observations complètes sur `Ht`, `Wt` et `PosRec`. Donner les effectifs, les moyennes et les écarts-types par position.

2. Pour `QB`–`OL`, construire la matrice de dispersion intragroupe W et la covariance commune $S_p = \frac{W}{n-2}$. Calculer, sans appeler `lda`, une direction de Fisher proportionnelle à $S_p^{-1}(\mu_{\mathrm{OL}} - \mu_{\mathrm{QB}})$. La normaliser pour que $a^\top S_p a = 1$ et l'orienter vers la moyenne des `OL`.

3. Définir le score centré $z(x) = a^\top\left(x - \frac{\mu_{\mathrm{QB}}+\mu_{\mathrm{OL}}}{2}\right)$ et classer en `OL` si $z(x) > 0$. Tracer cette frontière dans le plan (`Ht`, `Wt`). Projeter un joueur de taille 76.5 et de poids 335.5, puis donner sa classe. Vérifier les décisions avec `MASS::lda` en fixant les mêmes a priori. Distinguer le critère géométrique de Fisher des hypothèses qui donnent une interprétation probabiliste à la LDA.

4. Programmer une validation leave-one-out en réestimant les moyennes, S_p, la direction et le seuil après chaque retrait. Donner la matrice de confusion pour `QB`–`OL`. Refaire le calcul pour `OL`–`DL` et `DL`–`QB`, puis comparer l'exactitude globale et l'exactitude équilibrée (moyenne des rappels des deux classes).

5. Étendre l'analyse de Fisher aux trois positions avec `MASS::lda`. Combien d'axes peut-on obtenir ? Vérifier que la classe prédite est le centroïde le plus proche dans l'espace des deux axes, avec la normalisation intragroupe du logiciel. Donner la confusion leave-one-out et expliquer pourquoi les performances binaires et multiclasses ne répondent pas au même problème.

Exercice 7 — Positions NFL : interpréter les résultats d'une analyse de Fisher

On reprend les observations complètes et les deux prédicteurs de l'exercice précédent. L'objectif est de produire une interprétation des résultats de Fisher, en distinguant séparation des groupes, rôle des variables et qualité des prédictions. Les a priori sont fixés à $\frac{1}{3}$ pour `DL`, `OL` et `QB` et les coûts sont égaux.

1. Avec la graine `7480`, tirer environ 70% des joueurs de chaque position pour l'apprentissage et réserver les autres pour le test. Respecter l'ordre des classes `DL`, `OL`, `QB` et arrondir chaque effectif d'apprentissage avec `round`. Ajuster l'analyse uniquement sur l'apprentissage ; projeter le test avec ce même modèle.

2. Calculer `fit$svd^2 / sum(fit$svd^2)`. Quelle information porte cette répartition entre `LD1` et `LD2` ? Est-ce une proportion de variance totale expliquée, comme en ACP, ou un taux de bonne classification ?

3. Examiner les coefficients bruts des axes, les coefficients multipliés par les écarts-types d'apprentissage et les corrélations entre variables et scores d'apprentissage. Interpréter chaque axe. Pourquoi les valeurs absolues des coefficients bruts ne suffisent-elles pas à classer l'importance des variables ? Que changerait une inversion du signe de `LD1` ?

4. Tracer les observations et les centroïdes dans le plan (`LD1`, `LD2`), séparément pour l'apprentissage et le test. Quelle position se distingue surtout sur `LD1` ? Quelles positions se chevauchent encore ?

5. Construire la matrice de confusion du test. Calculer l'exactitude globale, le rappel de chaque classe et leur moyenne. Comparer le rappel des `QB` à la précision des prédictions `QB`. Expliquer leurs dénominateurs respectifs.

6. Comparer les prédictions obtenues avec `LD1` seul et avec les deux axes. Une faible part de séparation sur `LD2` signifie-t-elle que cet axe est inutile ? Pourrait-on choisir le nombre d'axes sur ce test puis présenter le même score comme une évaluation indépendante ?

7. Pour le joueur $(76.5, 335.5)$, interpréter les coordonnées, la classe prédite et les probabilités a posteriori. Rédiger une conclusion d'environ cinq lignes, avec au moins deux résultats chiffrés et une limite de l'analyse.