

Laboratoire - Généralités

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Identifier la tâche, l'espace et la géométrie

Pour chacun des scénarios suivants :

- préciser l'unité statistique et le nombre d'observations ;
 - proposer un problème de classification ou de régression, puis de prédiction ou d'inférence ;
 - décrire l'espace des variables explicatives du problème précédent;
 - proposer une dissimilarité ou distance et le prétraitement qu'elle exige ;
 - signaler une difficulté que la formulation initiale ne résout pas.
1. Cinq hôpitaux recrutent chacun 100 patients. On observe l'âge, l'indice de masse corporelle, le statut vaccinal et l'apparition d'une complication respiratoire.
 2. Une base contient 2000 ventes immobilières avec prix, superficie, nombre de chambres et présence d'un garage.
 3. Pendant 365 jours, on relève la concentration de PM2.5, la température, le vent et l'humidité dans une ville.
 4. Un sondage interroge 2000 personnes sur leur satisfaction de 1 à 5, leur âge, leur province, leur revenu et leur niveau d'éducation.
 5. On veut reconnaître quatre espèces animales à partir de trois mesures morphologiques relevées sur 1000 animaux.

Exercice 2 — Du mandat au plan d'analyse de données

Un service d'urgence dispose de 10000 visites. La base contient les heures d'arrivée, de triage, de première consultation et de sortie, le niveau de gravité, l'âge, le mode d'arrivée, l'occupation du service, les effectifs en poste et un retour éventuel dans les 72 heures. La direction demande de « trouver les causes de l'attente et construire un outil pour mieux planifier le personnel ».

1. Décomposer cette demande en une question descriptive, une question explicative ou causale et une question prédictive. Préciser la décision associée à chacune.
2. Définir la population cible, l'unité statistique et une variable réponse pour chaque question.
3. Pour la question causale, proposer un effet à estimer. Indiquer au moins trois obstacles empêchant une interprétation causale immédiate.
4. Pour la question prédictive, dresser la liste des variables disponibles au moment de la prédiction. Repérer les fuites d'information possibles.
5. Choisir un protocole de validation et des critères d'évaluation compatibles avec l'usage opérationnel.
6. Rédiger le squelette du plan d'analyse : analyses principales, analyses de sensibilité, diagnostics, livrables et critères d'acceptation.
7. Expliquer pourquoi un seul modèle ne répond pas nécessairement aux trois questions.

Exercice 3 — Choisir et calculer des distances

1. Un robot se déplace librement du point $(0,0)$ au point $(8,6)$. Calculer la distance euclidienne.
2. Sur une grille, un taxi va de l'intersection $(5,42)$ à $(1,114)$. Calculer la distance de Manhattan en unités de pâtés de maisons.
3. Un entrepôt est en $(10,15)$, le client A en $(18,22)$ et le client B en $(5,8)$. Comparer les proximités euclidienne et de Manhattan.
4. Calculer la distance de Hamming entre les messages 1001 et 1101.
5. Trois utilisateurs ont aimé les ensembles de films suivants :

$$U_1 = \{\text{Titanic}, \text{Avatar}, \text{Star Wars}, \text{Matrix}, \text{Inception}\},$$

$$U_2 = \{\text{Avatar}, \text{Matrix}, \text{Batman}, \text{Superman}, \text{Inception}\},$$

$$U_3 = \{\text{Inception}, \text{Avengers}, \text{Spiderman}, \text{Superman}, \text{Batman}\}.$$

Calculer les distances de Hamming sur l'univers total des films, puis les distances de Jaccard. Identifier les paires les plus proches.

6. Expliquer pourquoi le choix entre ces distances ne peut pas être séparé de la définition de l'espace et des unités.

Exercice 4 — Distance de Gower pour des données mixtes

Trois clients sont décrits par :

Client	Âge	Revenu	Fumeur	Satisfaction
A	20	30	non	4
B	50	60	oui	2
C	35	45	non	5

Le revenu est exprimé dans une même unité pour tous. Pour chaque variable quantitative ou ordinale, on divise l'écart absolu par l'étendue observée. Une variable nominale contribue 0 en cas d'égalité et 1 sinon. La distance de Gower est la moyenne des contributions disponibles.

1. Calculer les étendues des trois variables ordonnées.
2. Déterminer les quatre contributions puis la distance pour chaque paire.
3. Identifier les clients les plus proches.
4. Recalculer $d(A, C)$ si le revenu de C est manquant.
5. Discuter l'effet d'une valeur de revenu extrême sur toutes les distances.
6. Proposer deux pondérations si la satisfaction est jugée deux fois plus importante que chacune des autres variables.

Exercice 5 — Échelles, pondérations et changement de voisin

Une observation cible et deux observations candidates sont décrites par l'âge en années et le revenu annuel en dollars :

$$Q = (50, 50000), \quad A = (51, 80000), \quad B = (60, 52000).$$

1. Calculer les distances euclidiennes brutes de Q à A et à B . Quel est le plus proche voisin ?
2. Normaliser l'âge par une étendue de 20 ans et le revenu par une étendue de 100000 dollars, puis refaire le calcul. Que constate-t-on ?
3. Pour la distance normalisée pondérée

$$d_w^2(x, y) = w_a \left(\frac{x_a - y_a}{20} \right)^2 + w_r \left(\frac{x_r - y_r}{100000} \right)^2,$$

- déterminer la condition sur le rapport $\frac{w_a}{w_r}$ pour que A soit plus proche que B .
4. Expliquer pourquoi le choix des unités, de la transformation et des poids est une hypothèse sur la similarité, et non une opération neutre.
 5. Une variable nominale à m modalités est remplacée par m indicatrices. Quelle est la distance euclidienne entre deux modalités différentes ? Discuter le poids implicite de cette variable parmi d'autres prédicteurs.
 6. Dans une étude prédictive, sur quelles observations faut-il estimer les paramètres de standardisation ?

Exercice 6 — Décomposition biais-variance de l'erreur prédictive

À une valeur fixée x_0 , on observe

$$Y = f(x_0) + \varepsilon, \quad E(\varepsilon) = 0, \quad \text{Var}(\varepsilon) = \sigma^2.$$

Un algorithme entraîné sur un échantillon aléatoire produit $\hat{f}(x_0)$. Le nouvel écart ε est indépendant de l'échantillon d'entraînement.

1. Démontrer la décomposition

$$E\left[\left(Y - \hat{f}(x_0)\right)^2\right] = \sigma^2 + \text{Biais}\left(\hat{f}(x_0)\right)^2 + \text{Var}\left(\hat{f}(x_0)\right).$$

2. Interpréter chacun des trois termes.
3. Trois procédures ont les caractéristiques suivantes, avec $\sigma^2 = 2$:

Procédure	Biais au carré	Variance
A	4	0.5
B	1	1.5
C	0.1	5

Calculer l'erreur prédictive attendue et choisir la procédure.

4. Pourquoi la procédure la plus flexible peut-elle avoir la plus faible erreur d'entraînement et une mauvaise erreur future ?
5. Comment la taille de l'échantillon agit-elle généralement sur la variance ?

Exercice 7 — Sélection de modèle, validation et fuites d'information

Une équipe dispose de 1000 observations indépendantes et veut comparer 20 configurations. Elle prévoit 60% pour l'apprentissage, 20% pour la validation et 20% pour le test final. Certaines variables sont manquantes et doivent être imputées, puis standardisées.

1. Donner les tailles des trois sous-échantillons et le rôle de chacun.
2. Décrire l'ordre correct de l'imputation, de la standardisation, de l'ajustement et de l'évaluation.
3. Expliquer la fuite créée si les moyennes d'imputation et les écarts-types sont estimés sur les 1000 observations.
4. Pourquoi ne faut-il pas choisir la meilleure des 20 configurations sur le jeu de test ?
5. Proposer une validation croisée qui utilise mieux les 800 observations non réservées au test.
6. Adapter le protocole si les données sont temporelles ou regroupées par patient.
7. Après l'ouverture du test, dans quel cas peut-on annoncer honnêtement sa performance comme évaluation finale ?

Exercice 8 — Construire et exécuter un plan exploratoire avec `airquality`

Le jeu `airquality`, fourni avec R, contient des mesures quotidiennes de qualité de l'air et de météorologie à New York entre mai et septembre 1973. L'objectif est de produire une analyse exploratoire reproductible sans choisir les graphiques uniquement après avoir observé les résultats.

1. Avant de tracer un graphique, créer plan contenant au moins cinq questions. Pour chacune, préciser l'unité, les variables, la préparation, la production attendue et la décision que cette question pourrait déclencher.
2. Importer les données depuis R et construire un audit de la structure, des types, des valeurs manquantes, des étendues et des doublons potentiels.
3. Construire une date à partir de `Month` et `Day`. Vérifier que le couple mois-jour peut servir de clé dans ce fichier et signaler les limites de cette clé.
4. Produire seulement les tableaux et graphiques annoncés dans le plan : données manquantes, distribution de `Ozone`, évolution temporelle et relations avec `Temp` et `Wind`.
5. Créer un rapport indiquant les anomalies découvertes, la décision prise, sa justification et son effet sur les analyses suivantes.
6. Distinguer dans un court compte rendu les résultats prévus, les constats inattendus et les nouvelles hypothèses. Définir une règle d'arrêt pour cette première exploration.

Exercice 9 — Nettoyage et exploration d'un tableau désordonné

Le fichier `data_messy.csv` contient des informations synthétiques sur des personnes. Il comporte volontairement des doublons, formats incompatibles, valeurs manquantes et valeurs suspectes.

1. Importer le fichier sans convertir automatiquement les chaînes en facteurs. Définir explicitement les codes de valeurs manquantes.
2. Construire un audit indiquant dimensions, types, identifiants dupliqués, valeurs manquantes et modalités des variables qualitatives.
3. Créer une table nettoyée en traitant au minimum :
 - doublons d'identifiant ;
 - courriels invalides et numéros de téléphone hétérogènes ;
 - titres dans les noms ;
 - pays et réponses oui/non ;
 - dates écrites selon plusieurs formats ;
 - salaires non finis.
4. Repérer les salaires et nombres d'enfants atypiques par la règle de l'étendue interquartile. Les conserver avec un indicateur plutôt que les supprimer automatiquement.
5. Réaliser une exploration univariée et bivariée : distributions, fréquences, valeurs manquantes, relation entre salaire et nombre d'enfants.
6. Produire un rapport des transformations et expliquer pourquoi les colonnes d'adresse, de téléphone et de courriel demandent une protection particulière.

Exercice 10 — Illustrer le compromis biais-variance par simulation

La vraie fonction est

$$f(x) = 3 + 8x + 2x^2,$$

et les données suivent $Y = f(X) + \varepsilon$, avec $X \sim \mathcal{N}(0, 1)$, $\varepsilon \sim \mathcal{N}(0, 5)$, indépendants.

1. Simuler un échantillon d'entraînement de taille 50 et représenter le nuage avec la vraie courbe.
2. Ajuster des polynômes de degrés 1, 2 et 10. Comparer leurs erreurs d'entraînement.
3. Répéter l'expérience 500 fois. Sur une grille fixe de $[-1.5, 1.5]$, stocker les prédictions de chaque procédure.
4. Estimer, pour chaque degré, le biais au carré intégré, la variance intégrée et l'erreur prédictive attendue $5 + \text{biais}^2 + \text{variance}$.
5. Tracer quelques courbes ajustées pour visualiser la stabilité.
6. Expliquer pourquoi le domaine choisi pour mesurer le biais et la variance doit être annoncé.

Exercice 11 — Programmer une validation croisée sans fonction spécialisée

On ne connaît plus la forme de f . Il faut sélectionner le degré polynomial uniquement à partir des données.

1. Simuler 150 observations avec le modèle de l'exercice précédent.
2. Construire aléatoirement cinq plis de tailles aussi égales que possible.
3. Écrire une fonction `cv_polynomial` qui, pour un degré donné, ajuste cinq modèles et renvoie les erreurs quadratiques de validation.
4. Comparer les degrés 1 à 10 par l'erreur moyenne et son erreur-type.
5. Appliquer la règle du minimum, puis la règle d'une erreur-type.
6. Expliquer comment imbriquer ce choix si une estimation finale non biaisée est requise.