

Laboratoire - k-moyennes

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Silhouette et pseudo- R^2

Six observations unidimensionnelles a, b, c, d, e, f prennent respectivement les valeurs 1, 2, 3, 4, 5, 6. On utilise la distance euclidienne et la partition $C_1 = \{a, b, c\}$, $C_2 = \{d, e, f\}$.

1. Calculer la silhouette $s(c)$ de l'observation c et l'interpréter. On note $a(c)$ sa distance moyenne aux autres observations de son groupe et $b(c)$ sa plus petite distance moyenne à un autre groupe.
2. Calculer le pseudo- $R^2 = 1 - W/T$, où $T = \sum_i (x_i - \bar{x})^2$ est l'inertie totale et $W = \sum_k \sum_{i \in C_k} (x_i - \bar{x}_k)^2$ l'inertie intragroupe.

Exercice 2 — Itérations des k-moyennes

On cherche à répartir les cinq observations suivantes en $K = 2$ groupes :

Observation	1	2	3	4	5
x_{i1}	-1	-0.5	0	0.5	1
x_{i2}	-1	0	0.5	-0.5	1

Pour rendre l'initialisation reproductible, on part de $C_1^{(0)} = \{1, 3, 5\}$ et $C_2^{(0)} = \{2, 4\}$.

1. Calculer les deux centroïdes initiaux.
2. Calculer les distances euclidiennes au carré entre chaque observation et les deux centroïdes, puis l'inertie intragroupe initiale $W(C^{(0)})$.
3. Réassigner chaque observation au centroïde le plus proche et recalculer les centroïdes.
4. Effectuer les itérations suivantes jusqu'à stabilisation. Donner la partition finale et son inertie W .

Exercice 3 — Optimum des k-moyennes en dimension un

On observe les valeurs ordonnées 0, 1, 2, 8, 9, 10 et l'on cherche $K = 2$ groupes.

1. Montrer que, pour des centroïdes fixés $\mu_1 < \mu_2$, la règle du plus proche centroïde produit deux intervalles séparés en $(\mu_1 + \mu_2)/2$.
2. Il suffit donc, à l'optimum, d'examiner les cinq coupures entre deux valeurs consécutives. Calculer l'inertie intragroupe de chacune d'elles.
3. Déterminer la partition globale optimale et ses centroïdes.
4. Que devient cette partition si toutes les observations subissent la transformation $x_i^* = 3x_i - 7$?

Exercice 4 — Choisir le nombre de groupes

Sur un même tableau, des solutions de k -moyennes donnent :

K	Inertie W_K	Silhouette moyenne
1	240	—
2	120	0.42
3	72	0.51
4	58	0.44
5	50	0.39

1. Calculer le pseudo- $R_K^2 = 1 - W_K/T$ avec $T = W_1 = 240$.
2. Pourquoi la minimisation brute de W_K choisirait-elle toujours le plus grand K considéré ?
3. Quel nombre de groupes paraît ici le plus défendable ? Donner un argument fondé sur le coude et un autre fondé sur la silhouette.
4. Citer deux vérifications supplémentaires avant de donner une interprétation substantielle aux groupes.

Exercice 5 — Exprimer l'inertie par les distances entre observations

Soit un groupe non vide C de taille n_C , de moyenne $\bar{x}_C$.

1. Montrer que

$$\sum_{i \in C} \|x_i - \bar{x}_C\|^2 = \frac{1}{2n_C} \sum_{i \in C} \sum_{j \in C} \|x_i - x_j\|^2.$$

2. Réécrire cette identité avec une somme sur les seules paires $i < j$. Vérifier les deux expressions pour le groupe $\{0, 2, 4\}$.
3. En déduire une expression du critère des k-moyennes utilisant seulement les distances euclidiennes entre les observations d'un même groupe. Pourquoi le facteur dépendant de la taille de chaque groupe est-il essentiel ?
4. Peut-on remplacer sans précaution ces distances par n'importe quelle matrice de dissimilarité et conserver l'interprétation par des centroïdes euclidiens ?

Exercice 6 — Old Faithful : régimes d'éruption et effets d'échelle

Le jeu `datasets::faithful` contient 272 observations du geyser Old Faithful : `eruptions` mesure la durée d'une éruption et `waiting` le temps d'attente jusqu'à la suivante. Les deux variables sont en minutes.

1. Vérifier les dimensions et l'absence de valeurs manquantes. Représenter le nuage et comparer les écarts-types des deux variables.
2. Standardiser les variables, puis ajuster les k-moyennes pour $K = 1, \dots, 6$, avec cent démarrages par valeur de K . Calculer l'inertie et, pour $K \geq 2$, la silhouette moyenne. Retenir la plus grande silhouette, avec le plus petit K en cas d'égalité.
3. Décrire les effectifs et les moyennes des groupes retenus dans les unités d'origine. Numéroté les groupes par durée moyenne d'éruption croissante.
4. Au même K , refaire les ajustements sur les données brutes, puis après conversion de la seule durée d'éruption en secondes. Comparer les affectations par des contingences et trois graphiques dans les mêmes coordonnées initiales.
5. Pourquoi un simple changement d'unité peut-il modifier les groupes ? Peut-on choisir la meilleure représentation en comparant directement les trois inerties numériques ?

Exercice 7 — Suisse : variables supplémentaires et sensibilité de la typologie

Le jeu `datasets::swiss` décrit 47 unités territoriales de Suisse francophone vers 1888. On utilise `Agriculture`, `Examination`, `Education`, `Catholic` et `Infant.Mortality` pour construire les groupes. L'indice `Fertility` est réservé à leur description ultérieure.

1. Consulter `help("swiss")`, préciser le sens des cinq variables, puis les standardiser. Ajuster les k-moyennes avec $K = 3$ et cent démarrages. Ce nombre de groupes est imposé pour l'exercice.
2. Retirer successivement chacune des cinq variables et réajuster les k-moyennes sur les quatre autres, avec le même K . Comparer chaque partition à la référence par la proportion de paires d'observations dont le statut « même groupe » change.
3. Quelle variable a le retrait le plus influent ? Examiner la contingence correspondante et expliquer pourquoi ce diagnostic ne dépend pas des numéros arbitraires des groupes.
4. Pour la partition de référence, donner les effectifs, les unités territoriales et les profils moyens, en incluant maintenant `Fertility`. Tracer sa distribution par groupe. Pour la présentation, ordonner les groupes selon sa moyenne croissante, une fois la partition fixée.
5. Pourquoi ces résultats n'établissent-ils ni un effet causal des variables sur la fécondité, ni une règle applicable aux individus ? Que changerait l'utilisation de `Fertility` pour choisir les variables ou K ?