

Laboratoire - k-NN

Steven Golovkine

Automne 2026

Exercices

Exercice 1 — Les k plus proches voisins comme règle locale

On dispose d'un échantillon $(x_i, y_i)_{i=1}^n$. Pour une distance fixée, $\mathcal{N}_k(x)$ désigne les indices des k observations les plus proches de x , avec $1 \leq k \leq n$. Les égalités de distance sont départagées par l'indice croissant des observations.

1. Pour une réponse qualitative à K classes, définir une estimation locale $\hat{p}_g(x)$ de $P(Y = g \mid X = x)$ et la règle de classification associée.
2. Montrer que le vote majoritaire minimise, parmi les classes possibles, le nombre d'erreurs sur les voisins sélectionnés. Que faut-il préciser si plusieurs classes obtiennent le même nombre de voix ?
3. Pour une réponse quantitative, minimiser $\sum_{i \in \mathcal{N}_k(x)} (y_i - a)^2$ par rapport à a . Quelle prédiction obtient-on ? Que devient-elle avec une perte absolue ?
4. Décrire les cas $k = 1$ et $k = n$. Pourquoi parle-t-on d'une méthode non paramétrique ?

Exercice 2 — Distances, vote et pondération des voisins

On souhaite classer $x_0 = (0, 0)^\top$ à partir des cinq observations suivantes, en utilisant la distance euclidienne.

Indice	x_{i1}	x_{i2}	Classe
1	0.5	0	A
2	0	1	B
3	1	1	B
4	2	0	A
5	0	3	B

1. Calculer et ordonner les distances à x_0 .
2. Donner les classes prédites pour $k = 1, 3$ et 5 , avec un vote majoritaire. Pour $k = 3$, calculer les deux fréquences locales de classe.
3. Pour $k = 3$, attribuer au voisin i un poids proportionnel à $d(x_0, x_i)^{-1}$. Calculer les fréquences pondérées et la classe prédite.
4. Expliquer comment traiter une distance nulle et une égalité de distance à la limite du voisinage. Ces problèmes sont-ils résolus en prenant un k impair ?

Exercice 3 — Erreur apparente et validation leave-one-out

On observe six couples, ordonnés par abscisse :

Indice	1	2	3	4	5	6
x_i	0	1	3	7	8	10
y_i	A	A	B	B	B	A

On utilise la distance absolue et un vote uniforme.

1. Calculer l'erreur du 1-NN lorsque chaque observation peut être son propre voisin.
2. Retirer successivement chaque observation, prédire sa classe à partir des cinq autres, puis calculer l'erreur *leave-one-out* pour $k = 1$ et $k = 3$.
3. Choisir k parmi ces deux possibilités. Peut-on présenter le minimum obtenu comme une estimation sans optimisme de l'erreur du modèle choisi ?
4. Quel problème poserait une copie exacte d'une observation répartie entre apprentissage et validation ?

Exercice 4 — Iris : choisir k , la pondération et la standardisation

Le jeu `iris`, livré avec R, contient 150 fleurs de trois espèces et quatre mesures quantitatives. On cherche à prédire `Species`.

1. Réserver aléatoirement 15 fleurs par espèce pour le test, et utiliser les 35 restantes par espèce pour l'apprentissage. Fixer une graine.
2. Construire cinq plis stratifiés dans l'apprentissage. Comparer $k \in \{1, 3, 5, 9, 15, 25\}$, deux pondérations (une uniforme, une par distance) et les données brutes ou standardisées. Réestimer la standardisation dans chaque pli.
3. Choisir la configuration de plus petite erreur de validation croisée. À égalité, retenir le plus grand k , puis la première configuration dans l'ordre de la grille. Représenter les erreurs en fonction de k .
4. Réajuster le prétraitement retenu sur tout l'apprentissage. Évaluer une seule fois le modèle choisi sur le test avec une matrice de confusion, le taux de bonnes prédictions et la moyenne des sensibilités des trois espèces.
5. Interpréter les résultats. Pourquoi une seule partition ne suffit-elle pas à conclure à la supériorité générale d'une pondération ou d'une mise à l'échelle ?

Exercice 5 — Régression k -NN et ajout de variables sans information

On simule le modèle

$$X \sim \mathcal{U}(-1, 1), \quad Y = \sin(\pi X) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.2^2),$$

où le bruit est indépendant de X . On ajoute jusqu'à vingt variables uniformes sur $[-1, 1]$, indépendantes entre elles, de X et du bruit.

1. Générer 180 observations d'apprentissage et 1000 observations de test indépendantes. Construire trois représentations contenant X seul, X et cinq variables inutiles, puis X et vingt variables inutiles. Conserver les mêmes réponses et observations dans les trois cas.
2. Pour chaque représentation, choisir k parmi 1, 3, 5, 9, 15, 25, 45 et 75 par validation croisée à cinq plis. Employer des poids uniformes et standardiser dans chaque pli.
3. Évaluer sur le test la RMSE de prédiction de Y et la MSE d'estimation de la vraie fonction $\sin(\pi X)$. Comparer avec la prédiction constante égale à la moyenne des réponses d'apprentissage.
4. Pour la représentation contenant X seul, tracer la prédiction sur $[-1.5, 1.5]$. Décrire son comportement dans et hors du domaine observé.
5. Expliquer pourquoi la standardisation ne suffit pas à éliminer l'effet des variables inutiles. Comment évaluer honnêtement une sélection de variables destinée à remédier au problème ?

Exercice 6 — Décomposition biais-variance avec les k-plus proches voisins

On souhaite illustrer empiriquement la décomposition de l'erreur quadratique moyenne

$$E\left[\left(Y_0 - \hat{f}(x_0)\right)^2\right] = \sigma^2 + \text{Biais}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0)).$$

1. Choisir une fonction de régression non linéaire f , une taille d'échantillon n et une variance de bruit σ^2 . Générer des jeux de données selon $Y = f(X) + \varepsilon$, où $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.
2. Quel paramètre des k -plus proches voisins contrôle la flexibilité de l'estimateur ? Dans quel sens agit-il ?
3. Fixer un unique point x_0 . Pour plusieurs valeurs de k , simuler un grand nombre de nouveaux échantillons d'apprentissage et calculer $\hat{f}(x_0)$ sur chacun d'eux.
4. Estimer séparément le biais au carré, la variance, l'erreur irréductible et la MSE de test. Cette dernière doit être calculée directement à l'aide de nouvelles réponses Y_0 , et non obtenue par addition des trois autres termes. Représenter les résultats et vérifier numériquement la décomposition.