

TD: GENERALITÉS

EXERCICE 2 : On note i la 1^{re} obs et j la 2^{de} obs.

① Classification \rightarrow complication respiratoire ou non.

Prédiction \rightarrow une personne hospitalisée.

Nb obs \rightarrow 5×100 patients.

$\Omega \rightarrow$ $\underbrace{IN}_{\text{âge}} \times \underbrace{R+}_{\text{IMC}} \times \underbrace{\{oui, non\}}_{\text{statut vaccinal}} \times \underbrace{\{oui, non\}}_{\text{complication respiratoire}}$

Distance $\rightarrow |age_i - age_j| + |IMC_i - IMC_j| +$
 $1/\{vaccin_i \neq vaccin_j\} + 1/\{resp_i \neq resp_j\}$.

② Regression \rightarrow prix de vente du maisons.

Inférence \rightarrow "modéliser"

Nb obs \rightarrow 2000

$\Omega \rightarrow$ $\underbrace{R+}_{\text{surface}} \times \underbrace{IN}_{\text{nb chambres}} \times \underbrace{\{oui, non\}}_{\text{garage}} \times \underbrace{R+}_{\text{prix}}$

Distance $\rightarrow |surf_i - surf_j| + |cham_i - cham_j| + 1/\{gar_i \neq gar_j\} +$
 $|prix_i - prix_j|$.

③ Regression \rightarrow concentration quotidienne de PM2.5.

Inférence \rightarrow Pas d'indice sur le fait que l'on voudrait prédire.

Nb obs \rightarrow 365 (sur une année)

$\Omega \rightarrow \mathbb{R}^4$

Distance $\rightarrow \left(\sum_{i=1}^n (x_i - y_i)^2 \right)^{1/2}$

④ Classification \rightarrow réponses de 1 à 5.

Inférence \rightarrow emprouvement de la satisfaction.

Nb obs \rightarrow 2000

$\Omega \rightarrow \mathbb{N} \times \{QC, ON, \dots\} \times \mathbb{R}_+$
 $\times \{sans\ diplôme, secondaire, \dots\} \times \{1, \dots, 5\}$

Distance $\rightarrow |age_i - age_j| + 1 \mathbb{1}_{\{prov_i \neq prov_j\}} + |rev_i - rev_j|$
 $+ 1 \mathbb{1}_{\{dipl_i \neq dipl_j\}} + 1 \mathbb{1}_{\{satisf_i \neq satisf_j\}}$

⑤ Classification \rightarrow Types d'animaux.

Prédiction \rightarrow "identifier".

Nb obs \rightarrow 1000

$\Omega \rightarrow \mathbb{R}_+^3 \times \{castor, ours, cerf, wapitis\}$

Distance $\rightarrow \left[\sum_{i=1}^n (x_i - y_i)^2 \right]^{1/2} + 1 \mathbb{1}_{\{animal_i \neq animal_j\}}$

EXERCICE 3:

① Définition de l'objectif

En % du temps

5 %

② Collecte des données

10 %

③ Nettoyage des données

50 %

④ Conception du modèle

10 %

⑤ Implémentation du modèle

5 %

⑥ Analyse des résultats.

20 %

Exercice 4 :

- ① La distance la plus courte est donnée par la distance euclidienne (distance en ligne droite)

$$d(\text{début}, \text{fin}) = [(8-0)^2 + (6-0)^2]^{1/2} = 10$$

- ② La distance de Manhattan peut être utilisée pour calculer les distances dans NY (car les rues sont quadrillées).

$$d(\text{début}, \text{fin}) = |5-1| + |42-14| = 76.$$

- ③ Notons $X = \begin{pmatrix} 10 \\ 15 \end{pmatrix}$, $Y = \begin{pmatrix} 18 \\ 22 \end{pmatrix}$ et $Z = \begin{pmatrix} 5 \\ 8 \end{pmatrix}$

- À vol d'oiseau (distance euclidienne) :

$$d(X, Y) = [(18-10)^2 + (22-15)^2]^{1/2} = 10.63$$

$$d(X, Z) = [(5-10)^2 + (8-15)^2]^{1/2} = 8.60$$

À vol d'oiseau, le client le plus proche de l'entrepôt est le 2^{ème}.

- Sur une grille (distance de Manhattan)

$$d(X, Y) = |18-10| + |22-15| = 15$$

$$d(X, Z) = |5-10| + |8-15| = 12.$$

Sur une grille, le client le plus proche de l'entrepôt est le 2^{ème}.

$$④ d("1001", "1101") = \sum_{i=1}^4 1/y_i x_i \neq y_i y_i = 1$$

Le système de détection d'erreur ne peut pas détecter

la différence entre les deux messages car il n'y a qu'un bit de différence.

$$\textcircled{5} \quad d(u_1, u_2) = 1 + 0 + 1 + 1 + 0 + 1 + 1 \\ = 5$$

$$d(u_1, u_3) = 1 + 1 + 1 + 1 + 0 + 1 + 1 + 1 + 1 \\ = 8$$

$$d(u_2, u_3) = 1 + 1 + 0 + 0 + 0 + 1 + 1 + 0 + 0 \\ = 4$$

Les utilisateurs les plus proches sont les 2 et 3.