

TD: Généralités.

1. Preuve de la distance de Jaccard.

Soit x, y des variables binaires à K entrées.

Ex: $x = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} \quad y = \begin{pmatrix} 0 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$

• Indice de Jaccard: $J(x, y) = \frac{P_{11}}{K - M_{00}}$

• Distance de Jaccard: $d(x, y) = 1 - J(x, y)$
 $= \frac{P_{10} + P_{01}}{P_{00} + P_{10} + P_{11}}$

• Positivité: tous les termes au numérateur et au dénominateur sont $> 0 \Rightarrow d(x, y) > 0$.

• Séparation: supposons que $d(x, y) = 0$.

Alors $P_{10} + P_{01} = 0$. Donc il n'y a pas de variables qui 0 pour x et 1 pour y et inversement. Comme $P_{00} + P_{10} + P_{11} > 0$, on a $x = y$.


Supposons $x = y$. Alors $M_{00} = P_{10} = 0$. donc $d(x, y) = 0$

• Symétrie: L'indice de Jaccard est symétrique donc $d(x, y) = d(y, x)$

$X = \{i \in \{1, \dots, K\} \mid x_i = 1\} \rightarrow \text{ensemble des indices tel que } x_i = 1$

$Y = \{i \in \{1, \dots, K\} \mid y_i = 1\} \rightarrow \text{ensemble des indices tel que } y_i = 1.$

1.



$\{1, \dots, K\}$

$M_{01} \rightarrow \{i \in Y \mid i \notin X\}$

$M_{10} \rightarrow \{i \in X \mid i \notin Y\}$

On note $|A| = \text{card}(A)$
le cardinal de l'ensemble A

2. $d(x, y) = \frac{M_{01} + M_{10}}{M_{01} + M_{10} + M_{11}}$ (i.e. le nb d'éléments à $x \in A$)

$$M_{11} = |X \cap Y|$$

$$M_{10} = |X \setminus Y| \text{ et } M_{01} = |Y \setminus X|$$

$$\text{donc } M_{10} + M_{01} = |X \setminus Y \cup Y \setminus X| = |X \Delta Y|$$

$$\text{et } M_{10} + M_{01} + M_{11} = |X \cup Y|$$

$$\text{donc } d(x, y) = \frac{|X \Delta Y|}{|X \cup Y|}.$$

3. $A = \{1, 2\}, B = \{2, 3\} \text{ et } C = \{3, 4\}$

$$d(A, B) = \frac{|11 \cup 13|}{|11, 13|} = \frac{|11, 13|}{|11, 13|} = \frac{2}{2}$$

$\{1, 2, 3\}$

$\{1, 2, 3\}$

3

$$d(B, C) = \frac{|124 \cup 146|}{|123, 45|} = \frac{2}{3}$$

$$d(A, C) = \frac{|11, 24 \cup 3, 45|}{|11, 2, 3, 45|} = 1$$


4. $Z = \{i \in \{1, \dots, 14\} \mid z_i = 1\}$.

$$\begin{aligned} d(x, y) &\leq d(x, z) + d(z, y) \\ \Rightarrow \frac{|x \Delta y|}{|x \cup y|} &\leq \frac{|x \Delta z|}{|x \cup z|} + \frac{|z \Delta y|}{|z \cup y|} \end{aligned}$$

5. $M_q X \Delta Y \subseteq (X \Delta Z) \cup (Y \Delta Z)$.

bit $a \in X \Delta Y$. $\forall q a \in (X \Delta Z) \cup (Y \Delta Z)$.

$$a \in X \Delta Y \Leftrightarrow a \in X \setminus Y \cup Y \setminus X$$




$$(X \Delta Z) \cup (Y \Delta Z) = \underline{X \setminus Z \cup Z \setminus X \cup Y \setminus Z \cup Z \setminus Y}$$

done a \in X \Delta Z \cup Y \Delta Z

6. $M_q X \cup Y \subseteq (X \cup Z) \cup (Y \cup Z)$

bit $a \in X \cup Y$. $\forall q a \in (X \cup Z) \cup (Y \cup Z)$



7. Soit A et B des ensembles, on a :

1. Modularité : $|A \cup B| + |A \cap B| = |A| + |B|$

2. Monotonicité : Si $A \subseteq B$, alors $|A| \leq |B|$

3. Non négativité : $|A| \geq 0$.

→ Pour tous ensembles X, Y, Z , on a.

~~(*)~~ $|X \cap Z| \cdot |Y \cap Z| + |X \cup Z| \cdot |Y \cap Z| \leq |Z| \cdot [|X| + |Y|]$.

Preuve :

$$\begin{aligned} \bullet |X \cap Z| \cdot |Y \cap Z| &= |X \cap Z| \cdot [|Y| + |Z| - |Y \cap Z|] \\ &= |X \cap Z| \cdot |Y| + |X \cap Z| \cdot |Z| - |X \cap Z| \cdot |Y \cap Z| \\ &\stackrel{\substack{\text{modularité} \\ \text{donc } |X \cap Z| \leq |Z|}}{\leq} |Z| \cdot |Y| + |X \cap Z| \cdot |Z| - |Z| \cdot |Y \cap Z| \\ &= |Z| \cdot [|Y| + |X \cap Z| - |Y \cap Z|] \end{aligned}$$

$$\begin{aligned} \bullet |X \cup Z| \cdot |Y \cap Z| &= |Y \cap Z| \cdot [|X| + |Z| - |X \cap Z|] \\ &= |Y \cap Z| \cdot |X| + |Y \cap Z| \cdot |Z| - |Y \cap Z| \cdot |X \cap Z| \\ &\stackrel{\substack{\text{modularité} \\ \text{donc } |Y \cap Z| \leq |Z|}}{\leq} |Z| \cdot |X| + |Y \cap Z| \cdot |Z| - |Z| \cdot |X \cap Z| \\ &= |Z| \cdot [|X| + |Y \cap Z| - |X \cap Z|] \end{aligned}$$

• Donc

$$|X \cap Z| \cdot |Y \cup Z| + |X \cup Z| \cdot |Y \cap Z|$$

$$\leq |Z| \cdot [|Y| + |X \cap Z| - |Y \cap Z| + |X| + |Y \cap Z| - |X \cap Z|]$$

$$= |Z| \cdot [|X| + |Y|]$$

■

→ Pour tout ensemble S et T , on a

$$(\star) |S \cap T| \cdot |S \cup T| \leq |S| \cdot |T|.$$

Preuve: Preuve $X = S$, $Y = S$ et $Z = T$ dans (\star)

$$|S \cap T| \cdot |S \cup T| + |S \cup T| \cdot |S \cap T| \leq |T| \cdot 2|S|$$

$$\Leftrightarrow |S \cap T| \cdot |S \cup T| \leq |S| \cdot |T|.$$

→ Pour tout ensemble X, Y , et Z , $d(X, Y) \leq d(X, Z) + d(Y, Z)$

où d est la distance de Jaccard définie par

$$d(X, Y) = \frac{|X \Delta Y|}{|X \cup Y|} = 1 - \frac{|X \cap Y|}{|X \cup Y|}.$$

Preuve: On doit montrer que :

$$1 - \frac{|X \cap Y|}{|X \cup Y|} \leq 1 - \frac{|X \cap Z|}{|X \cup Z|} + 1 - \frac{|Y \cap Z|}{|Y \cup Z|}$$

$$\Leftrightarrow \frac{|X \cap Z|}{|X \cup Z|} + \frac{|Y \cap Z|}{|Y \cup Z|} \leq 1 + \frac{|X \cap Y|}{|X \cup Y|} = \frac{|X| + |Y|}{|X \cup Y|}$$


modularité

$$\frac{|X \cap Z|}{|X \cup Z|} + \frac{|Y \cap Z|}{|Y \cup Z|} = \frac{|X \cap Z| \cdot |Y \cup Z| + |Y \cap Z| \cdot |X \cup Z|}{|X \cup Z| \cdot |Y \cup Z|}$$

$$(*) \quad \frac{|Z| \cdot [|X| + |Y|]}{|X \cup Z| \cdot |Y \cup Z|}$$

$$\frac{S = X \cup Z}{T = Y \cup Z} \quad (*) \quad \frac{|Z| \cdot [|X| + |Y|]}{|(X \cup Z) \cap (Y \cup Z)| \cdot |X \cup Y \cup Z|}$$

$$\frac{X \cup Y \subseteq X \cup Y \cup Z}{\text{done } |X \cup Y| \leq |X \cup Y \cup Z|} \quad \frac{|Z|}{|(X \cap Y) \cup Z|} \cdot \frac{|X| + |Y|}{|X \cup Y|}$$



$$Z \subseteq (X \cap Y) \cup Z \quad \frac{|X| + |Y|}{|X \cup Y|}$$

done $|Z| \leq |(X \cap Y) \cup Z|$

ce qui achève la démonstration !